Master D2SN – Traces numériques et dynamiques de l'innovation

Etude d'Open Food Facts

PHAM Dong Pha

June Camille Ménard

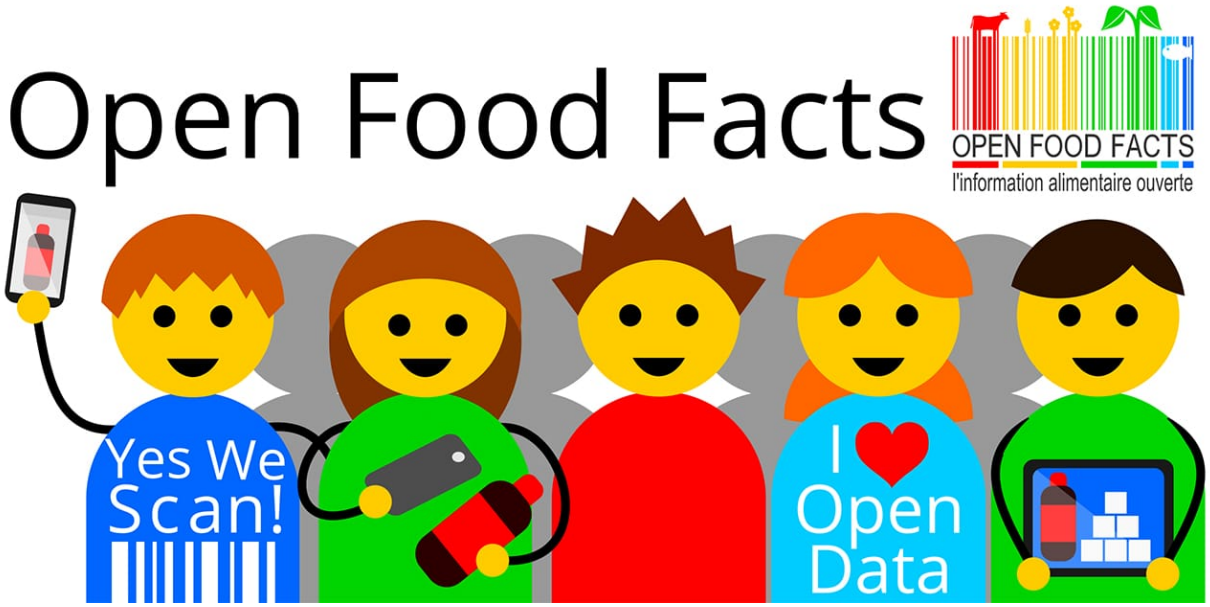

Nous avons recherché le terme de produit «blé» et téléchargé les données sur le site Web: Open Fact Food. Nous avons une base de données avec plus de 7000 produits

Nous allons maintenant utiliser ces ensembles de données à bon escient en explorant les données à l'aide de méthodes telles que le regroupement, la visualisation et les tests d'hypothèses. Nous devons d'abord importer certains packages dont nous aurons besoin pour l'exploration.

Entrée [57]:
```
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
import seaborn as sns
import statsmodels.formula.api as sm
import re
import sqlite3
from datetime import datetime
from pandas import Series, DataFrame
sns.set()
%matplotlib inline
```

Entrée [58]:
```
data = pd.read_csv("C:/Users/phamd/Downloads/openfoodfacts_search.csv")
```

```
C:\Users\phamd\anaconda3\lib\site-packages\IPython\core\interactiveshell.py:305
0: DtypeWarning: Columns (0,6,11) have mixed types.Specify dtype option on impo
rt or set low_memory=False.
  has_raised = await self.run_ast_nodes(code_ast.body, cell_name,
```

Entrée [59]:
```
data.head()
```

Out[59]:

	code	url	creator	created_t	last_modi
0	3760247570137	https://fr.openfoodfacts.org/produit/376024757...	kiliweb	1621876151	16218
1	3700977701012	https://fr.openfoodfacts.org/produit/370097770...	kiliweb	1563014460	16218
2	7613037397956	https://fr.openfoodfacts.org/produit/761303739...	kiliweb	1570024144	16218
3	3770019493014	https://fr.openfoodfacts.org/produit/377001949...	foodvisor	1621854431	16218
4	3256540035126	https://fr.openfoodfacts.org/produit/325654003...	openfoodfacts-contributors	1428781797	16218

5 rows × 174 columns

Entrée [60]:
```
print('Il y a {:,} lignes '.format(data.shape[0]) + 'et {} colonnes dans ce datas
```

```
Il y a 7,023 lignes et 174 colonnes dans ce dataset
```

Entrée [61]:
```
# On liste toutes les colonnes
sorted(data.columns.tolist())
```

Out[61]:
```
['-alpha-linolenic-acid_100g',
 '-arachidic-acid_100g',
 '-arachidonic-acid_100g',
 '-behenic-acid_100g',
 '-butyric-acid_100g',
 '-capric-acid_100g',
 '-caproic-acid_100g',
 '-caprylic-acid_100g',
 '-cerotic-acid_100g',
 '-dihomo-gamma-linolenic-acid_100g',
 '-docosahexaenoic-acid_100g',
 '-eicosapentaenoic-acid_100g',
 '-elaidic-acid_100g',
 '-erucic-acid_100g',
 '-fructose_100g',
 '-gamma-linolenic-acid_100g',
 '-glucose_100g',
 '-gondoic-acid_100g',
 '-insoluble-fiber_100g',
```

Traitement des NaN et des doublons

Entrée [62]:
```
data.isnull().sum().sort_values()
```

Out[62]:
```
code                            0
url                             0
creator                         0
created_t                       0
last_modified_t                 0
                               ...
-gamma-linolenic-acid_100g    7023
-arachidonic-acid_100g        7023
-linoleic-acid_100g           7023
beta-carotene_100g            7023
carnitine_100g                7023
Length: 174, dtype: int64
```

Entrée [63]:
```
# Nous renommons toutes les colonnes contenant un "-" car dans certains scénarios
data = data.rename(columns={'nutrition-score-fr_100g': 'nutrition_score_fr_100g',
                            'nutrition-score-uk_100g' : 'nutrition_score_uk_100g
                            'energy-kj_100g': 'energy_kj_100g',
                            'carbon-footprint_100g':'carbon_footprint_100g',
                            'trans-fat_100g':'trans_fat_100g',
                            'energy-from-fat_100g': 'energy_from_fat_100g'})
```

Entrée [64]:
```
data.isnull().sum().plot(kind='hist', figsize=(15,10))
plt.title('Répartition des NaN')
plt.xlabel('NaNs')

plt.show()
```

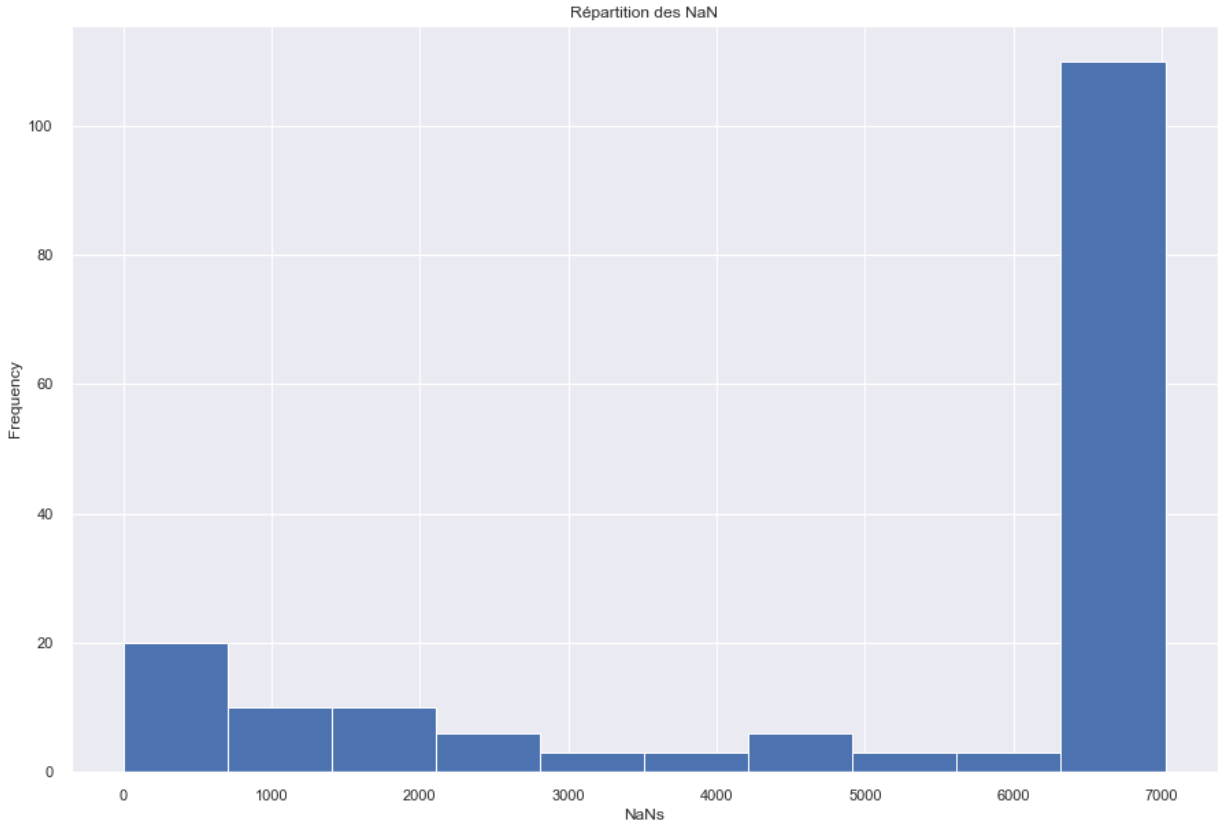

Entrée [65]:
```
# Nous supprimons toutes les colonnes contenant moins de 20% de données utilisabl
data = data.dropna(axis=1, thresh= len(data)*0.2, how='all')
```

Entrée [66]:
```
# supprimer toutes les lignes qui (après avoir supprimé certaines colonnes) ne co
data = data.dropna(axis=0, how='all')
```

Entrée [67]:
```
print('Il y a maintenant {:,} lignes '.format(data.shape[0]) + "et {} colonnes re
```

```
Il y a maintenant 7,023 lignes et 61 colonnes restantes dans nos données
```

Entrée [68]:
```
data.isnull().sum().sort_values()
```

Out[68]:
```
code                          0
url                           0
creator                       0
created_t                     0
last_modified_t               0
                            ...
manufacturing_places       4661
manufacturing_places_tags  4661
additives_tags             5039
origins                    5435
origins_tags               5436
Length: 61, dtype: int64
```

Entrée [69]:
```
# Statistiques
data.describe()
```

Out[69]:

	created_t	last_modified_t	serving_quantity	additives_n	ingredients_from_palm_oil_n	i
count	7.023000e+03	7.023000e+03	2490.000000	4978.000000	4978.000000	
mean	1.501100e+09	1.592289e+09	76.743265	1.443953	0.054841	
std	6.593993e+07	3.496606e+07	74.950636	2.436531	0.227693	
min	1.331999e+09	1.382886e+09	0.000000	0.000000	0.000000	
25%	1.457641e+09	1.582736e+09	30.000000	0.000000	0.000000	
50%	1.513796e+09	1.607093e+09	60.000000	0.000000	0.000000	
75%	1.542551e+09	1.615319e+09	100.000000	2.000000	0.000000	
max	1.621876e+09	1.621876e+09	1000.000000	17.000000	1.000000	

Entrée [70]:
```
data['product_name'].fillna(value='Product name unavailable', inplace=True)
```

Entrée [71]:
```
data.head()
```

Out[71]:

	code	url	creator	created_t	last_modi
0	3760247570137	https://fr.openfoodfacts.org/produit/376024757...	kiliweb	1621876151	16218
1	3700977701012	https://fr.openfoodfacts.org/produit/370097770...	kiliweb	1563014460	16218
2	7613037397956	https://fr.openfoodfacts.org/produit/761303739...	kiliweb	1570024144	16218
3	3770019493014	https://fr.openfoodfacts.org/produit/377001949...	foodvisor	1621854431	16218
4	3256540035126	https://fr.openfoodfacts.org/produit/325654003...	openfoodfacts-contributors	1428781797	16218

5 rows × 61 columns

Entrée [72]:
```
# Nous supprimons tous les doublons de nos données
data.drop_duplicates(inplace=True)
data.head()
```

Out[72]:

	code	url	creator	created_t	last_modi
0	3760247570137	https://fr.openfoodfacts.org/produit/376024757...	kiliweb	1621876151	16218
1	3700977701012	https://fr.openfoodfacts.org/produit/370097770...	kiliweb	1563014460	16218
2	7613037397956	https://fr.openfoodfacts.org/produit/761303739...	kiliweb	1570024144	16218
3	3770019493014	https://fr.openfoodfacts.org/produit/377001949...	foodvisor	1621854431	16218
4	3256540035126	https://fr.openfoodfacts.org/produit/325654003...	openfoodfacts-contributors	1428781797	16218

5 rows × 61 columns

Exploratoire des données partie 1

Entrée [74]:
```
countries=data['countries'].value_counts().head(10).to_frame()
s = countries.style.background_gradient(cmap='Blues')
s
```

Out[74]:

	countries
France	5198
en:fr	614
en:france	169
en:France	88
en:FR	79
France,Suisse	52
Francia,España	46
France,en:france	37
France, Suisse	28
Belgique,France	28

Entrée [75]:
```
brands= data['brands'].value_counts().head(10).to_frame()
k = brands.style.background_gradient(cmap='Reds')
k
```

Out[75]:

	brands
U	452
Carrefour	168
Auchan	139
Casino	101
Panzani	88
Leader Price	72
Brossard	66
Barilla	64
Monoprix	59
Tipiak	52

Exploration du supermarché: Super U

Entrée [76]:
```
##Filtrer les données et ne gardez que les produits de la marque U:
data1=data[data['brands']=='U']
```

Entrée [77]:
```
data1=data1.fillna(0, axis=1)
```

Entrée [78]:
```
data1_corr=data1.corr()
f,ax=plt.subplots(figsize=(10,7))
sns.heatmap(data1_corr, cmap='viridis')
plt.title("Corrélation entre les caractéristiques",
          weight='bold',
          fontsize=18)
plt.xticks(weight='bold')
plt.yticks(weight='bold')

plt.show()
```

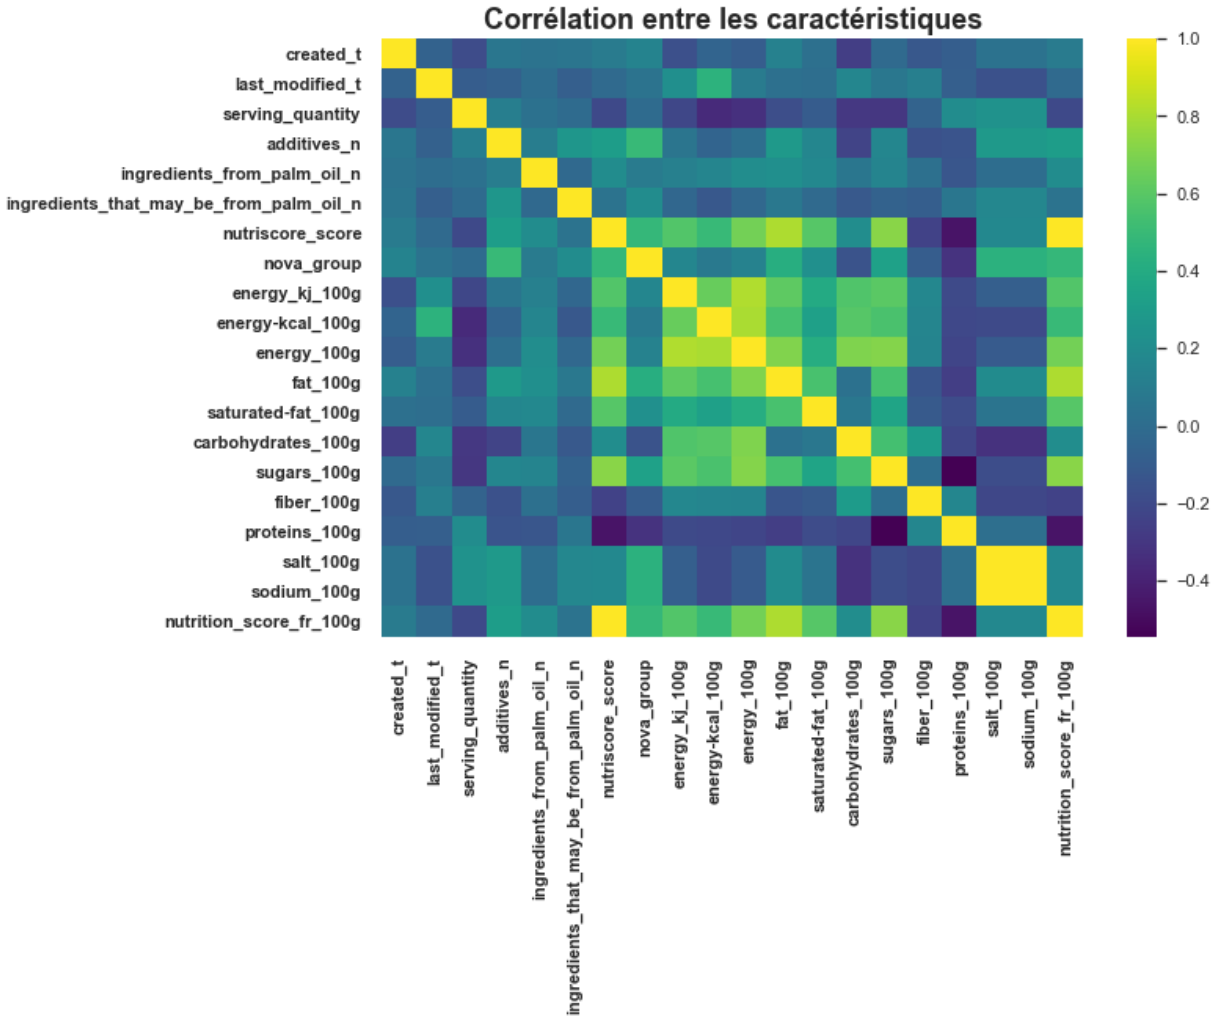

Entrée [79]:
```
plt.figure(figsize=(15, 6))

plt.scatter(x=data1['nutrition_score_fr_100g'], y=data1['energy_100g'], color='de
plt.title("Score nutritionnel français pour les produits de Super U en fonction d
          weight='bold',
          fontsize=15)
plt.xlabel('Score nutritionnel France', weight='bold', fontsize=14)
plt.ylabel('Calories', weight='bold', fontsize=14)
plt.xticks(fontsize=12, weight='bold')
plt.yticks(fontsize=12,weight='bold')


plt.show()
```

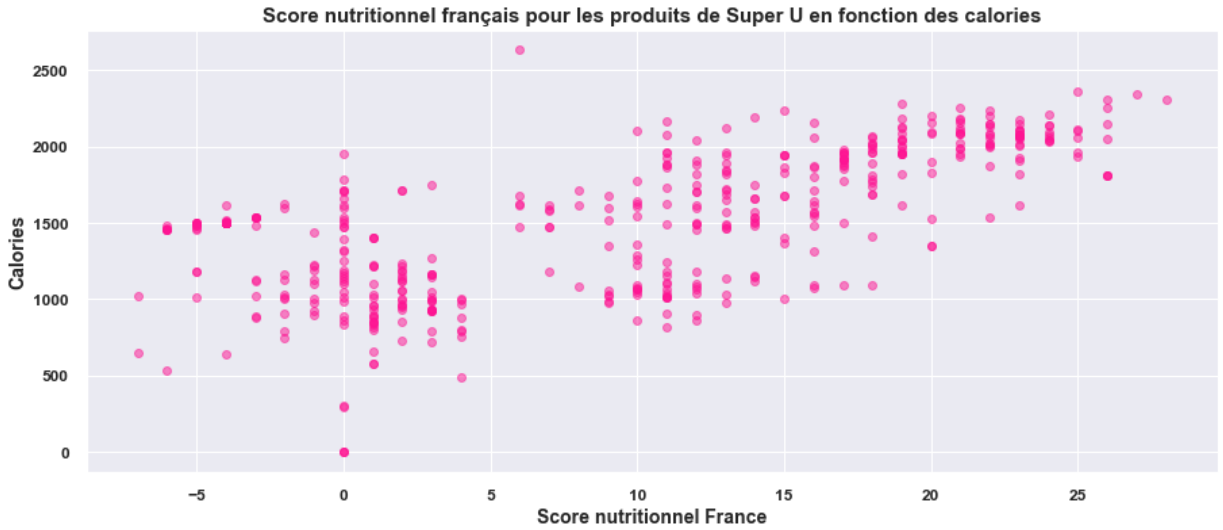

Entrée [80]:
```
data2=data1[['product_name','energy_100g', 'fat_100g',
       'saturated-fat_100g', 'carbohydrates_100g', 'sugars_100g',
       'proteins_100g']]
print(f"Nous avons {data2.shape[0]} produits dans les supermarchés U et {data2.sh
```

```
Nous avons 452 produits dans les supermarchés U et 7 features
```

Régime keto: guide d'achat dans le supermarché U

Entrée [81]:
```
keto= data2[(data2['energy_100g']<2000)&(data2['carbohydrates_100g']<40)&(data2[
print(f'Nous avons {keto.shape[0]} Produits blé dans le supermarché U')
```

```
Nous avons 130 Produits blé dans le supermarché U
```

En filtrant les colonnes, on aboutit à 130 produits sur 452, ce qui signifie:

"si tu veux aller keto, tu dois abandonnerplus des deux tiers de la nourriture disponible au supermarché"

La distribution des valeurs nutritives dans les produits céto filtrés:

Entrée [82]:
```
plt.style.use('seaborn')
sns.set_style('whitegrid')

fig= plt.figure(figsize=(15,10))
#2 rows 2 cols
#first row, first col
ax1 = plt.subplot2grid((2,2),(0,0))
plt.hist(keto.energy_100g, bins=3, color='orange', alpha=0.7)
plt.title('Calories',weight='bold', fontsize=18)
plt.yticks(weight='bold')
plt.xticks(weight='bold')
#first row sec col
ax1 = plt.subplot2grid((2,2), (0, 1))
plt.hist(keto.fat_100g, bins=3, alpha=0.7)
plt.title('Fat',weight='bold', fontsize=18)
plt.yticks(weight='bold')
plt.xticks(weight='bold')
#Second row first column
ax1 = plt.subplot2grid((2,2), (1, 0))
plt.hist(keto.proteins_100g, bins=3, color='red', alpha=0.7)
plt.title('Protein',weight='bold', fontsize=18)
plt.yticks(weight='bold')
plt.xticks(weight='bold')
#second row second column
ax1 = plt.subplot2grid((2,2), (1, 1))
plt.hist(keto.carbohydrates_100g, bins=3, color='green', alpha=0.7)
plt.title('Carbs',weight='bold', fontsize=18)
plt.yticks(weight='bold')
plt.xticks(weight='bold')
```

Out[82]:
```
(array([-5.,  0.,  5., 10., 15., 20., 25., 30., 35., 40., 45.]),
 [Text(0, 0, ''),
  Text(0, 0, ''),
  Text(0, 0, ''),
  Text(0, 0, ''),
  Text(0, 0, ''),
  Text(0, 0, ''),
  Text(0, 0, ''),
  Text(0, 0, ''),
  Text(0, 0, ''),
  Text(0, 0, ''),
  Text(0, 0, '')])
```

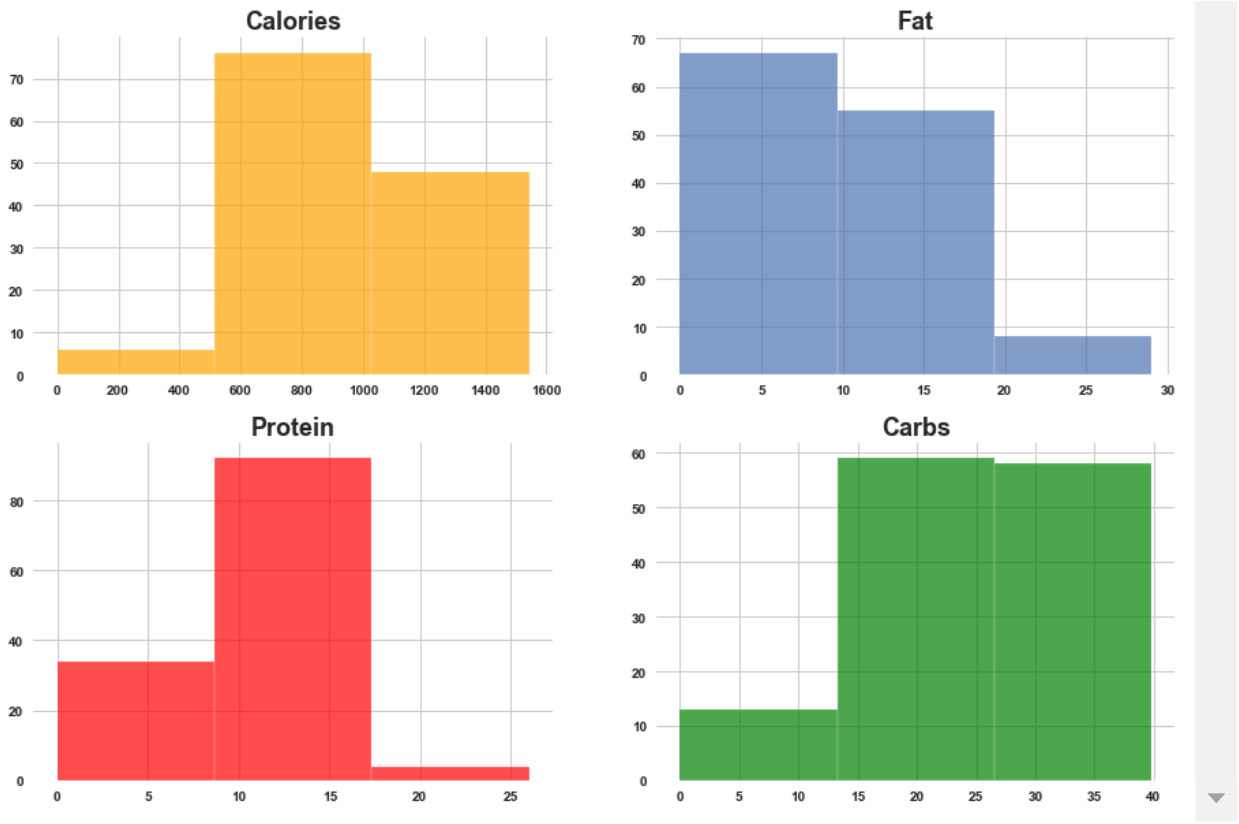

Élimination des valeurs aberrantes

Entrée [83]:
```
data.describe()
```

Out[83]:

	created_t	last_modified_t	serving_quantity	additives_n	ingredients_from_palm_oil_n	i
count	7.023000e+03	7.023000e+03	2490.000000	4978.000000	4978.000000	
mean	1.501100e+09	1.592289e+09	76.743265	1.443953	0.054841	
std	6.593993e+07	3.496606e+07	74.950636	2.436531	0.227693	
min	1.331999e+09	1.382886e+09	0.000000	0.000000	0.000000	
25%	1.457641e+09	1.582736e+09	30.000000	0.000000	0.000000	
50%	1.513796e+09	1.607093e+09	60.000000	0.000000	0.000000	
75%	1.542551e+09	1.615319e+09	100.000000	2.000000	0.000000	
max	1.621876e+09	1.621876e+09	1000.000000	17.000000	1.000000	

L'inspection perdante des valeurs min et max révèle qu'il y a des erreurs évidentes dans nos données.

Entrée [84]:
```
data.select_dtypes(include=float).plot(kind='box', subplots=True, title='Nos donn

plt.show()
```

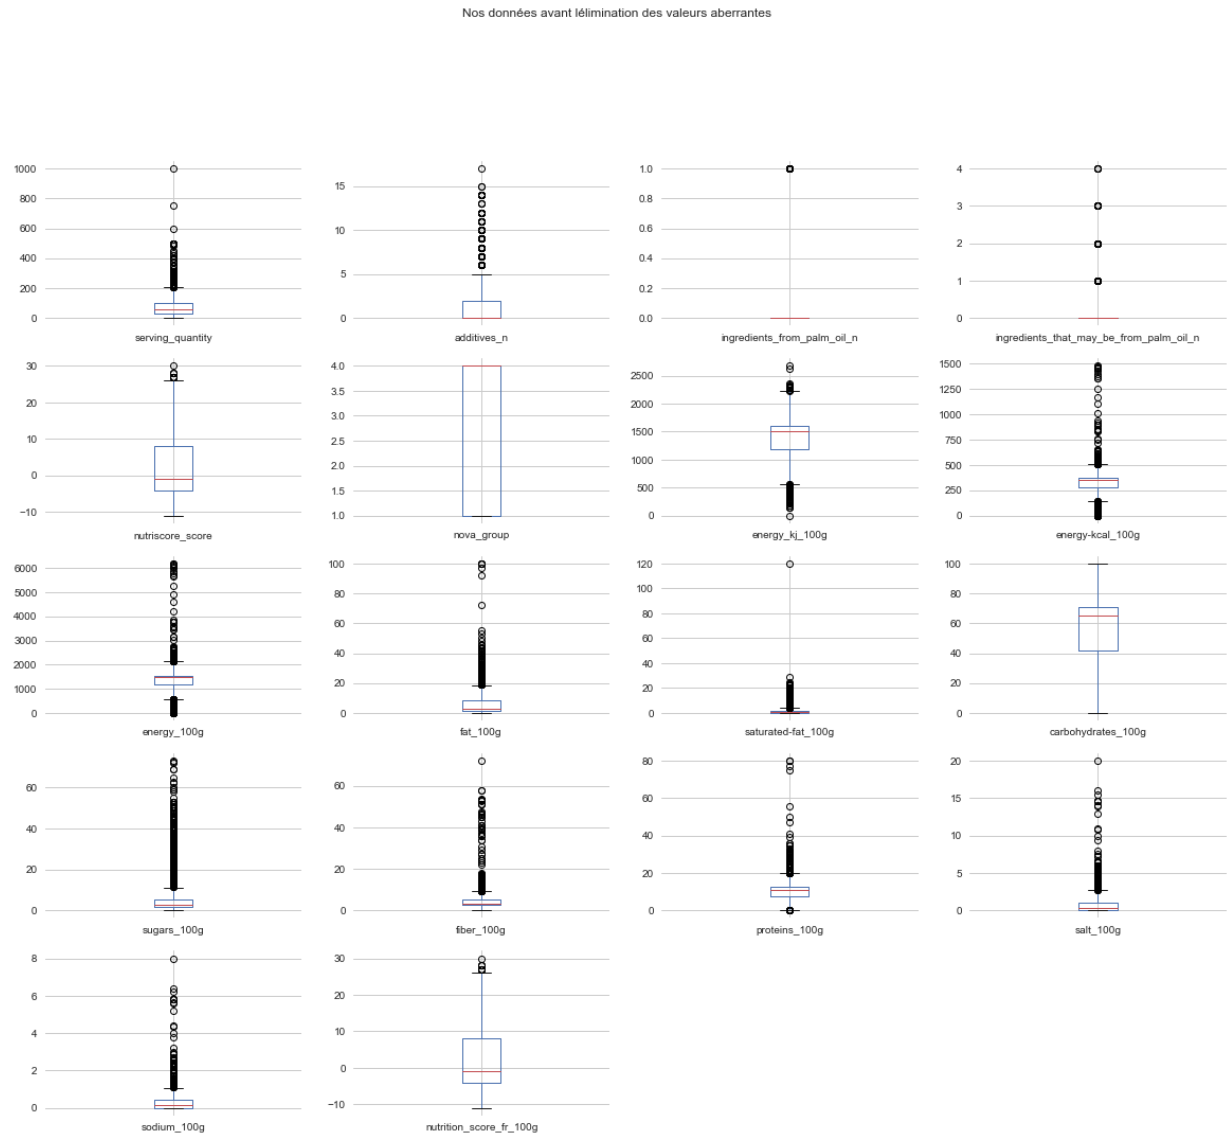

Standardisation

Entrée [85]:
```
stand_data = data.select_dtypes(include=float).transform(lambda x: (x - x.mean())
```

Entrée [86]:
```
stand_data.describe()
```

Out[86]:

	serving_quantity	additives_n	ingredients_from_palm_oil_n	ingredients_that_may_be_from_p
count	2.490000e+03	4.978000e+03	4.978000e+03	4.97
mean	2.237835e-16	-1.520323e-15	-2.808008e-16	-1.0
std	1.000000e+00	1.000000e+00	1.000000e+00	1.0(
min	-1.023917e+00	-5.926268e-01	-2.408562e-01	-3.4
25%	-6.236540e-01	-5.926268e-01	-2.408562e-01	-3.4
50%	-2.233906e-01	-5.926268e-01	-2.408562e-01	-3.4
75%	3.102940e-01	2.282124e-01	-2.408562e-01	-3.4
max	1.231820e+01	6.384507e+00	4.151020e+00	9.3(

Entrée [87]:
```
stand_data.dropna(inplace=True)
```

Entrée [88]:
```
print('Il y a {:,} lignes '.format(stand_data.shape[0]) + "et {} colonnes dans no
```

```
Il y a 945 lignes et 18 colonnes dans nos données standardisées
```

Exploratoire des données partie 2

- Dans la première moitié de notre enquête, nous nous concentrerons principalement sur les trois domaines suivants:
- Fréquences (comment nos variables sont-elles réparties et quels sont les additifs et ingrédients les plus courants?)
- Caractéristiques (quelles sont les caractéristiques des différentes catégories et pays?)
- Relations (comment les variables sont-elles liées les unes aux autres)
- Nous étudierons par la suite nos données avec des corrélations et des analyses de régression.

Fréquences

Distributions

Entrée [89]:
```
data.describe()
```

Out[89]:

	created_t	last_modified_t	serving_quantity	additives_n	ingredients_from_palm_oil_n	i
count	7.023000e+03	7.023000e+03	2490.000000	4978.000000	4978.000000	
mean	1.501100e+09	1.592289e+09	76.743265	1.443953	0.054841	
std	6.593993e+07	3.496606e+07	74.950636	2.436531	0.227693	
min	1.331999e+09	1.382886e+09	0.000000	0.000000	0.000000	
25%	1.457641e+09	1.582736e+09	30.000000	0.000000	0.000000	
50%	1.513796e+09	1.607093e+09	60.000000	0.000000	0.000000	
75%	1.542551e+09	1.615319e+09	100.000000	2.000000	0.000000	
max	1.621876e+09	1.621876e+09	1000.000000	17.000000	1.000000	

Entrée [90]:
```
data.hist(figsize=(20,20), layout=(6,4))

plt.show()
```

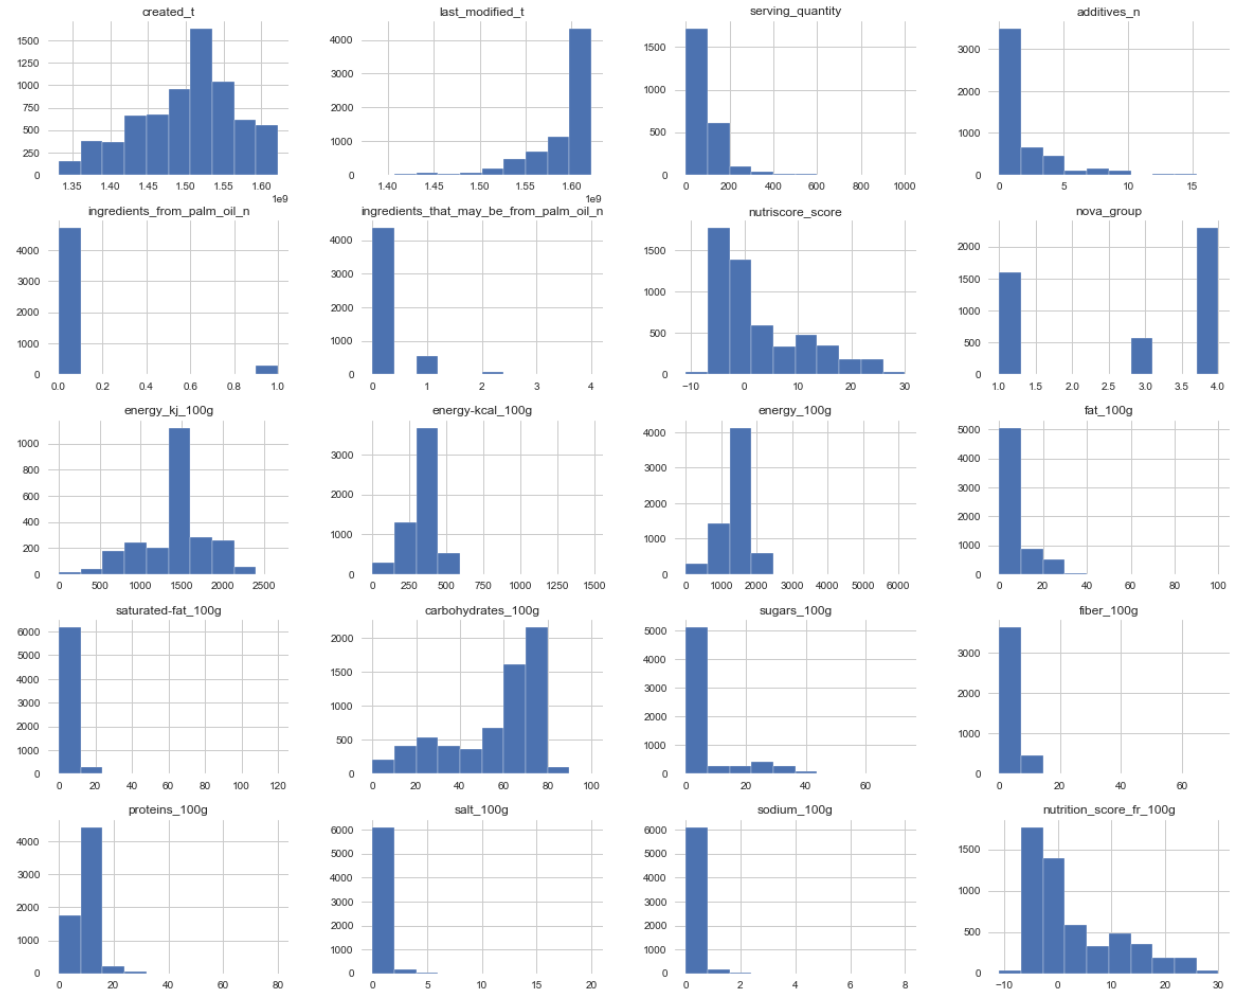

Analyse food packaging

Entrée [91]:
```
data["packaging"].groupby(data["packaging"]).count().sort_values(ascending=False)
```

Out[91]:
```
packaging
sachet,plastique                                                    247
Sachet,Plastique                                                    227
Sachet plastique                                                    220
sachet                                                              125
Carton                                                               99
                                                                   ...
carton,atmosphère protectrice,boite, fr:Etui en carton                1
carton,barquette plastique,plastique                                  1
carton,barquette,plastique                                            1
carton,barquette,plastique, fr:Etui en carton, fr:Film en plastique   1
07 o                                                                  1
Name: packaging, Length: 1628, dtype: int64
```

Les deux types d'emballage les plus courants semblent être le plastique, le sachet

Analyse du nombre d'additifs (additive count)

Entrée [92]:
```
plt.title("Distribution of additive count in products")
plt.xlabel("Additive count")
plt.ylabel("Additive count distribution")
plt.hist(data["additives_n"])
plt.show()
```

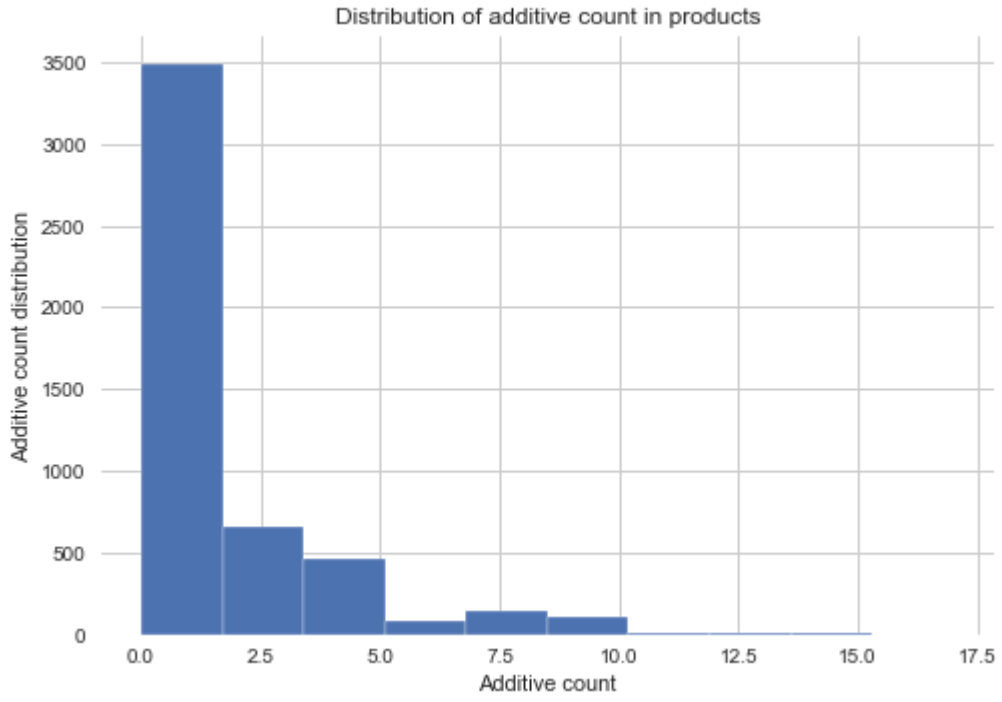

Nous pouvons voir que la distribution ici est asymétrique et que la

plupart des produits ont des additifs dans le champ de (0,5), ce qui est un bon indicateur.

Regroupons la colonne d'additifs par qualité nutritionnelle

Le dataframe groupé ici doit être de taille 5, un groupe pour chaque grade ("A", "B", "C", "D", "E").

Entrée [93]:
```
additives_by_grade=data["additives_n"].groupby(data["nutriscore_grade"])
```

Maintenant, traçons un histogramme des distributions.

Entrée [94]:
```
for additive, grade in additives_by_grade:
    plt.hist(grade, label = "Grade {}".format(additive), alpha = 0.5)
plt.title("Distribution of additive count by nutrition grade")
plt.xlabel("Additive count")
plt.ylabel("Additive count distribution")
plt.legend()
plt.show()
```

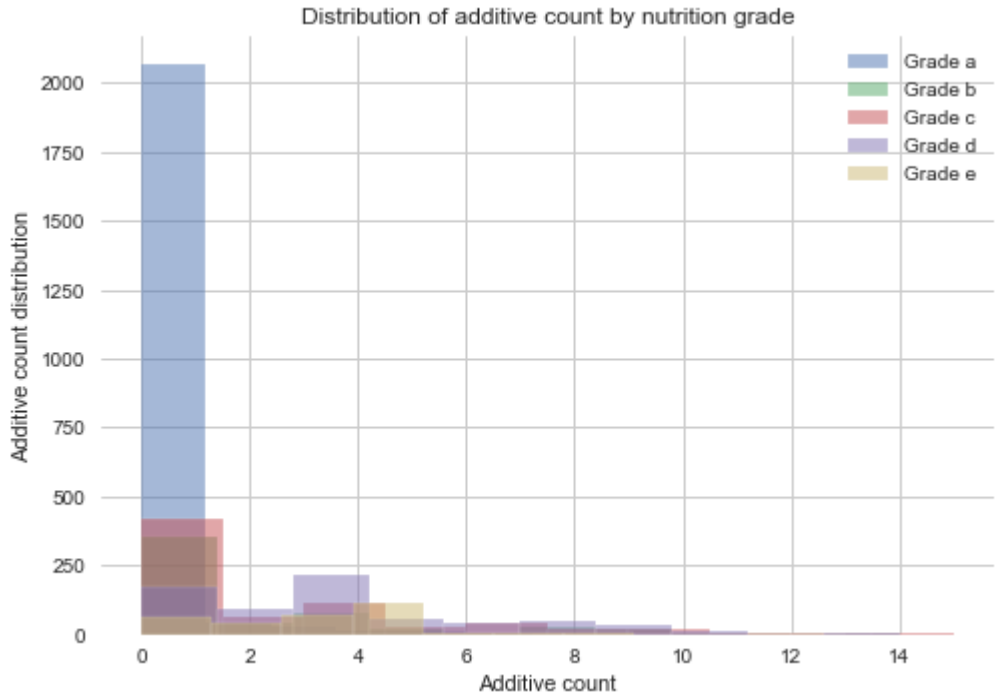

Il ne semble pas que le nombre d'additifs dans les produits affecte les qualités car les distributions sont plus ou moins les mêmes. Mais nous pouvons voir que la note prédominante ici est «D», ce qui signifie que beaucoup de produits ont une note élevée. Nous examinerons ensuite les ingrédients de l'huile de palme.

Analyse des catégories de produits

Nous pouvons également regarder les catégories avec le plus grand nombre de produits dans le dataframe. Prenons les 10 catégories avec le plus grand nombre de produits et voyons à quoi elles ressemblent.

Entrée [95]:
```
num_products_by_category=data.categories.groupby(data.categories).count().sort_va
```

Entrée [96]:
```
def plot_barh_on_grouped_data(grouped_data,title,y_label,fig_size):
    plt.figure(figsize = fig_size)
    plt.title(title)
    plt.ylabel(y_label)
    plt.barh(range(len(grouped_data)), grouped_data)
    plt.yticks(list(range(len(grouped_data))), grouped_data.index)
    plt.show()
```

Entrée [97]:
```
plot_barh_on_grouped_data(num_products_by_category,"Catégories de produits franç
```

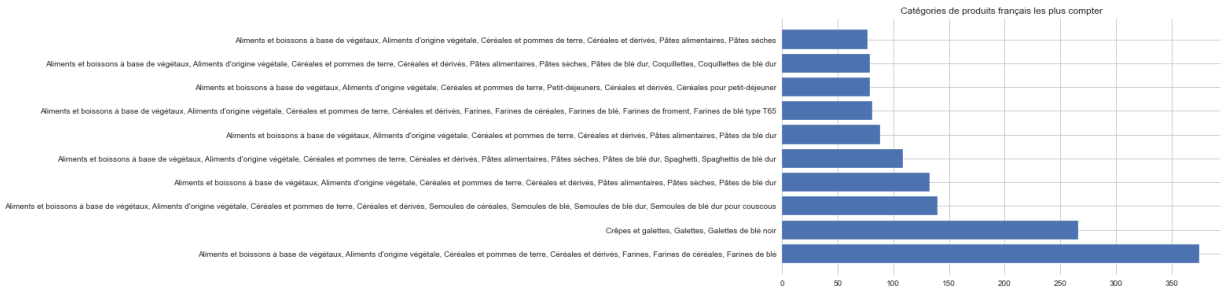

Il semble que la majorité de cette base de données comprend des produits à base de plantes. Dans la plupart des cas, ces produits devraient en fait être ceux qui ont le meilleur score nutritionnel. Cela devrait normalement signifier que la plupart des produits ont des qualités plus élevées. Mais est-ce vraiment le cas?.

Nous allons regrouper les catégories par grade

Entrée [98]:
```
grades_by_category
```

Out[98]:
```
nutriscore_grade
a    2710
b     642
c     877
d     787
e     344
Name: main_category, dtype: int64
```

Entrée [99]:
```
grades_by_category=data.main_category.groupby(data.nutriscore_grade).count()
```

Entrée [100]:
```
plot_barh_on_grouped_data(grades_by_category,"Nutrition grade distributions for
```

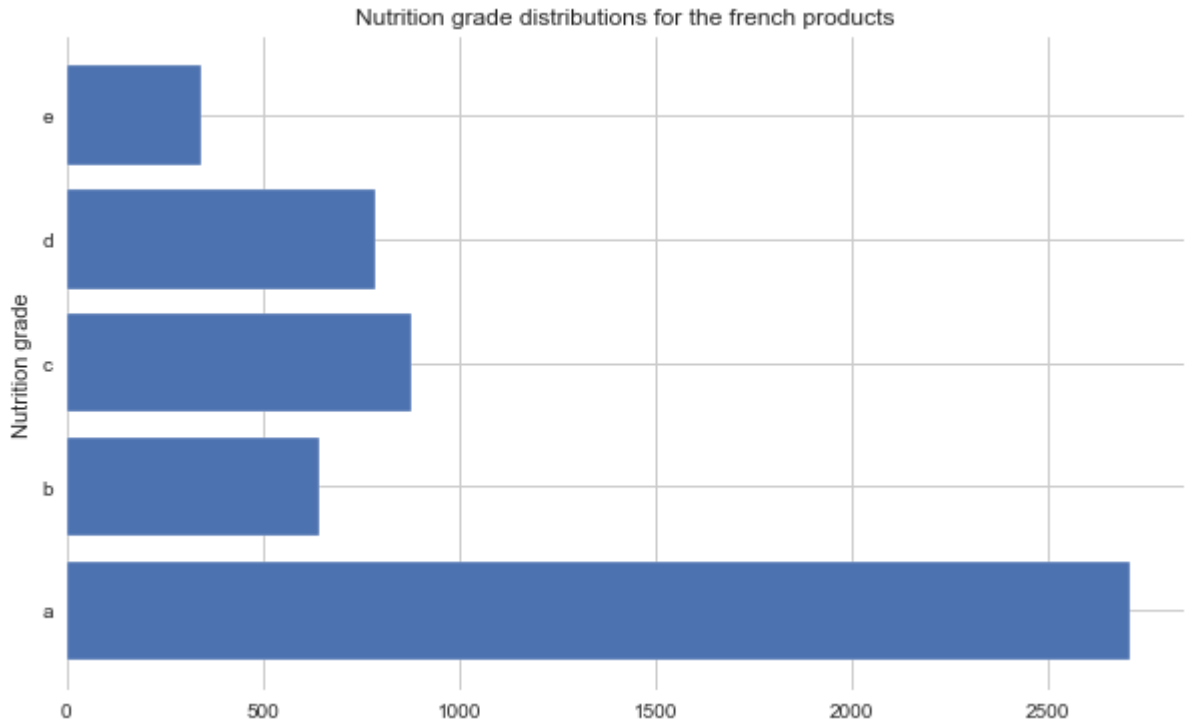

D'après ce que nous pouvons voir, les trois notes les plus basses sont celles avec le plus petit nombre! Peut-être que les produits français sont aussi sains qu'il y paraît après tout.

Top 5 des corrélations entre les variables

Entrée [101]:
```
def get_redundant_pairs(df):
    '''Obtenir des paires diagonales et triangulaires inférieures de matrice de
    pairs_to_drop = set()
    cols = df.columns
    for i in range(0, df.shape[1]):
        for j in range(0, i+1):
            pairs_to_drop.add((cols[i], cols[j]))
    return pairs_to_drop

def get_top_abs_correlations(df, n=5):
    au_corr = df.corr().abs().unstack()
    labels_to_drop = get_redundant_pairs(df)
    au_corr = au_corr.drop(labels=labels_to_drop).sort_values(ascending=False)
    return au_corr[0:n]
```

Entrée [102]:
```
print('Le top 5 des corrélations entre les variables sont: \n{}'.format(get_top_
```

```
Le top 5 des corrélations entre les variables sont:
nutriscore_score  nutrition_score_fr_100g    1.000000
energy_kj_100g    energy_100g                1.000000
salt_100g         sodium_100g                1.000000
energy-kcal_100g  energy_100g                0.993633
energy_kj_100g    energy-kcal_100g           0.970533
dtype: float64
```

Word Cloud - Product & catégories

Entrée [103]:
```
from collections import Counter
from wordcloud import WordCloud
```

Entrée [104]:
```
def wordclouding(data, label='product_name', sep=' '):
    """Pour renvoyer un nuage de mot présent dans la colonne 'étiquette', la sép
    words = []

    for string in data[label]:
        listwords= str(string).split(sep)
        for w in listwords:
            if (w!=' ')and (w!='nan'):
                words.append(w)
    count=Counter(words)


    wordcloud = WordCloud(width=1080, height=920, colormap='PuBuGn').fit_words(c
    plt.figure(figsize=(25,15))
    plt.imshow(wordcloud, interpolation='bilinear')
    plt.axis('off')
    plt.margins(x=0, y=0)
    plt.show()
```

Entrée [110]:
```
wordclouding(data, label='categories', sep=',')
```

Note : Nos données sont très désordonnées et de nombreuses entrées sont manifestement erronées. Nous pouvons facilement nettoyer de nombreuses imperfections, mais nous ne savons pas dans quelle mesure nous pouvons faire confiance à nos données nettoyées.

Entrée [ ]: